

Luna AI Assistant

サークル・ サイト範囲ルーティング 100問評価 / デプロイ前ドライラン

結論

100件の固定評価は、Lunaを使う範囲とローカル応答の範囲を分離して検証します。

このPDFはローカルdry-runであり、production endpoint、OpenAI API、AWS環境にはアクセスしていません。

64 Luna calls / 36 zero-call responses / 0 web calls

を固定契約として、ケースごとのscope、呼出し数、利用量、リンク、プライバシー境界を判定します。

指標	値	意味
固定ケース	100	25テーマ x 4表現ゆれ
モデル	gpt-5.6-luna	評価対象モデル
Luna呼出し	64	circle / site のみ、各1回
ローカル応答	36	university / conversation / out_of_scope は0回
Web呼出し	0	全ケースでツール無効
本番実測	0	このPDFはローカルdry-run

スコープと評価マトリクス

scope	ケース	Luna	リンク・応答境界
circle	32	1	TTI Intelligenceの活動・参加・作品
site	32	1	サイト内容とCodex/Vercel/AWS/Plugin/CLI/MCP
university	16	0	公式サイト root URL のみ
out_of_scope	16	0	短い案内、リンクなし
conversation	4	0	短い会話応答、リンクなし

判定すること

期待scopeとの一致、ケース固有のLuna/Web呼出し数、HTTP状態、遅延、必須・禁止概念、許可リンク、ゼロ呼出し時の5種token counterの全ゼロを検査します。大学ケースは <https://www.toyota-ti.ac.jp/> の完全一致だけを許可し、大学の詳細を説明する文章を失敗にします。

テレメトリーとプライバシー

相関記録とテレメトリーには run UUID、case ID、server request ID、観測時刻、assistantScope、期待/観測のLuna・Web呼出し数、token counterだけを保存します。質問文、履歴、session ID、回答本文、その他の私的内容は保存しません。

照合	要件
run	UUID、開始/終了時刻、100件のcase IDを完全一致
request	100個の一意なserver request IDを完全一致
telemetry	scopeと期待/観測呼出し数、ゼロ呼出しusageを検証
links	大学rootのみ、会話・範囲外はリンクなし

ローカル実行の境界

dry-runはfixtureと評価器、証跡ファイルの整合性だけを確認します。Luna payloadを構築せず、production/OpenAI呼出しを行いません。本番評価を認可した場合も、ローカルscopeのリクエストはsession IDを送らず、テレメトリーでゼロusageを要求します。

再現性と次の手順

dataset.json、results.json、results.csv、summary.jsonはmanifest.jsonのSHA-256で照合してからPDFを生成します。モデル、ツール無効、評価用の単価設定、実行状態はsummary.jsonに固定します。

本番未実行のため、正答率・遅延・token・費用は未測定です。デプロイ許可後に同じ凍結データセットを1回実行し、privacy-safe telemetryを照合してこのPDFを再生成します。

合格条件

100件のscope、case ID、server request ID、時刻範囲を一致させ、64件のcircle/siteでLuna 1回、36件のlocal scopeでLuna 0回かつ5つのusage counterがすべて0、全100件でWeb 0回を確認します。