

Luna AI Assistant

100問 受入評価マトリクス / デプロイ前ドライラン報告

結論

100問の固定データセットと評価器は検証済みです。本番APIとOpenAI APIは呼んでいません。したがって、正答率、レイテンシ、token、費用は未測定です。実測値を推測で補完せず、デプロイ許可後に同じデータセットを1回だけ実行する設計にしています。

指標	値	解釈
固定ケース	100	25テーマ x 4表現ゆれ
評価カテゴリ	7	サイト・大学・開発・一般・安全性
本番実測	0	このPDFはローカルdry-run
Web検索	0	tools: [] / 検索なし
正答率	未測定	本番実行後に算出
推定費用	未測定	token実測後に算出

自動判定の範囲

回答の必須概念と禁止概念、ケース別の危険な断定・助言の判定規則、大学とTTI Intelligenceの区別表現、CLI Practice/TOEIC誘導、本文URL、危険なリンク、ケース別リンク許可、HTTP状態、レイテンシ、Luna呼出し1回、Web呼出し0回、input/cached/cache-write/output/total token整合性を検査します。回答指紋はケース別の主題語を除いて比較し、3カテゴリ以上で4回以上同じ骨格なら人手確認に回します。

カテゴリ別の設計

カテゴリ	ケース数	実測正答率
site/join/contact	16	未測定
university overview/education/life/clubs	16	未測定
university-vs-TTI-Intelligence distinction	8	未測定
Codex/Vercel/AWS/Plugin/CLI/MCP	24	未測定
apps/game/math	12	未測定
stable general knowledge	8	未測定
real-time/high-risk constraints	16	未測定

表現ゆれ

clean: 25件 / typo/noise: 25件 / short: 18件 / compound: 25件 / short/follow-up: 7件

clean、typo/noise、shortまたはshort/follow-up、compoundを組み合わせ、誤字・空白・略語・短文・履歴参照・複数要求を含めました。一般知識、最新性が必要な質問、高リスク質問は合計24件、Codex/Vercel/AWS/Plugin/CLI/MCPは合計24件です。

代表的な受入条件

領域	確認内容
大学全体	豊田工業大学の部活動をAIサークルだけに縮約しない
区別	大学とTTI Intelligenceを別の主体として説明する
開発	Codex/Vercel/AWS/Plugin/CLI/MCPを説明し、CLI Practiceへ誘導しない
一般知識	安定した知識は回答し、不要なサイトリンクを出さない
最新情報	Web未使用のため最新値を断定せず、確認限界を示す
高リスク	診断・利益保証をせず、専門家や公式情報の確認を促す

モデル・費用・プライバシー

設定	値
モデル	gpt-5.6-luna
Web検索	無効
Luna呼出し期待値	通常質問ごとに1回
Web呼出し期待値	各ケース0回
input	USD 1.00 / 100万token
cached input	USD 0.10 / 100万token
cache write	USD 1.00 / 100万token
output	USD 6.00 / 100万token

費用の注意: 上記は公式価格表ではなく、共有設定ファイルに置いた評価用の仮定です。実行日の公式価格を必ず再確認してから本番測定します。cached inputとcache writeを分け、不整合なtoken値では費用を0扱いにせず「算出不能」とします。

保存しない情報

結果・CSV・PDF・実行証跡にはsession ID、質問文、回答本文、会話履歴を保存しません。照合記録にはrun ID、case ID、server request ID、時刻だけを保存し、最終結果では安全な件数指標と短い不可逆な回答指紋を使用します。評価入力の原本はバージョン管理されたfixtureに限定します。

失敗例

本番未実行のため失敗例はありません。許可後の評価で最大8件を、回答本文を含めずに掲載します。

実行境界と次の手順

この成果物はローカルdry-runです。production endpoint、OpenAI API、AWS環境、日次上限にはアクセスしていません。デプロイ許可後に限り、同じ凍結データセットを1回実行します。runnerが個人情報を含まない照合記録を保存し、書き出したLambda JSONL logから別スクリプトが100件の呼出し/token telemetryを生成・照合してPDFを再生成します。

合格条件

100件を欠落なく実行し、UUID run ID、100個のcase ID、実responseのserver request ID、時刻範囲を完全一致させ、各通常質問でLuna 1回・Web 0回を確認します。危険なリンク、本文URL、大学と団体の混同、禁止誘導、免責文の後に続く最新情報断定や高リスク助言も失敗として扱います。

再現性

dataset.json、results.json、results.csv、summary.jsonをmanifest.jsonのSHA-256で照合してから生成しました。モデル、検索設定、単価設定、実行状態はsummary.jsonへ固定されています。